

KL_oSA USER GUIDE

고령화연구패널조사 1차 조사 자료에서 발생하는
결측값에 대한 Multiple Imputation

- 대체된 자료의 분석 -

2007. 10.

고령화연구패널조사는 고령화 시대에 대비하기 위하여 한국의 고령자 모집단에 대한 실태를 파악하고 기초 자료를 수집하기 위하여 계획되었고 1차 조사가 2006년에 실시되었다. 2007년에는 1차 조사 자료에서 발생하는 결측값에 대하여 소득 및 자산 변수를 중심으로 한 다중대체(multiple imputation)가 시행되었다. 본 User Guide는 2007년 시행된 multiple imputation을 통하여 생성된 대체(impute)된 자료에 대한 사용자들의 이해를 돕고자 한다. 1장에서는 우선 multiple imputation을 위하여 사용된 imputation 모형에 대하여 간략히 설명하고 2장에서는 대체된 자료의 형태 및 자료에서 원래 관찰된 값과 대체된 값을 구별하는 방법에 대하여 설명한다. 3장에서는 대체된 자료를 사용하여 분석을 시행하는 방법에 관하여 설명하였다. Imputation 모형에 대한 자세한 설명 및 결과 비교는 KLoSA multiple imputation 결과 보고서(report)(송주원 외, 2007)에 나타난다.

1. 결측값 대체 방법

고령화연구패널조사의 경우 대부분의 변수에서 결측값(missing data)의 비율이 5%미만으로 작게 나타났으나 소득 및 자산 일부 항목에서 결측값의 비율은 10 - 20% 내외까지 증가하였으며 일부 응답자가 많지 않은 항목의 경우 약 30% 정도까지 나타났다. 따라서 결측값을 포함한 변수에 대한 적절한 분석을 위하여 결측이 발생한 주요 항목에 대하여 multiple imputation이 실시되었는데 특히 결측 비율이 높은 소득 및 자산 항목의 대체에 중점을 두고 진행되었다. 각 변수별 결측 비율이 거의 대부분의 변수에서 20% 미만으로 나타났으므로 imputation의 수는 5개로 결정하였다.

고령화연구패널조사는 전체 8개의 영역(session)으로 구성되어 있는데 결측값의 대체가 결측 비율이 높은 소득 및 자산 항목의 대체에 중점을 두고 진행되었지만 관련된 주요 변수들의 대체도 함께 실시되었다. 우선 인구영역의 주요 변수들이 5번 대체되었고 대체된 5개의 자료 각각에 대하여 주요 인구영역 변수 및 디자인 변수(design variables)들을 설명 변수로 사용하여 건강 영역 주요 변수의 대체를 실시하였다. 이렇게 대체된 5개 자료 각각에 근거하여 관련 변수를 설명 변수로 사용한 고용 영역의 현재 고용 및 퇴직 소득에 관한 대체를 실시하였다. 다음으로 각 대체된 자료에서 소득과 관련된 변수들을 설명 변수로 사용하여 소득 영역의 주요 소득 항목들에 대한 대체가 실시되었다. 이 때 자산 영역의 집 소유 여부 및 금융자산 총액도 설명변수로 포함되어 소득과 자산의 연관성을 설명하고자 하였다. 소득영역이 대체된 후 대체된 각 개인당 총소득을 계산한 후 다른 관련 변수들과 함께 설명 변수로 설정하여 주요 자산 영역 변수들에 대한 대체를 실시하였다. 마지막으로 가족 대표자만이 응답한 가족 영역 중 자녀의 수 및 자녀들에게서 지원받은 액수 및 지원한 액수에 관한 항목들을 대체하였다. Imputation 모형에 사용된 설명 변수에 관한 자세한 정보는 KLoSA multiple imputation 결과보고서에 기술되었다(송주원 외, 2007).

결측값의 대체를 위하여 사용 가능한 여러 가지 대체 방법(imputation method) 중 고령화 연구패널 자료의 결측값 대체에 적절할 것으로 사려되는 세 가지 대체법을 고려하였고 모의 실험을 실시하여 가장 좋은 결과를 나타낸 대체 방법인 수정된 예측 평균에 근거한 핫덱 방법(hotdeck based on a modified predictive mean matching)이 대체 방법으로 선택되었다. 이 방법은 Little(1988)이 제안한 일종의 핫덱 대체법(hotdeck imputation)으로서 미국 RAND의 Bell (1999)이 SAS Macro로 프로그램화하여 여러 가지 조사 연구에 적용해 왔고 우수한 결과를 보여 온 대체 방법이다. 이 방법은 결측이 발생한 자료값을 자료 내 관찰된 값들 중 하나 또는 여러 개의 값을 가지고 대체시키는 일종의 핫덱 대체법이지만 관찰값 중 하나 또는 여러 개의 값을 임의로 선택하는 랜덤 핫덱(random hotdeck) 대신 자료를 비슷한 여러 개의 하위 그룹(subclass)으로 나누어 같은 하위 그룹 내에서 핫덱 대체를 실시한다. 이 때 하위그룹은 결측이 발생한 변수에 대하여 관찰된 자료만을 대상으로 회귀모형(regression model)을 적합하여 결측이 포함된 모든 자료에 대한 예측값을 구한 후 예측값에 근거하여 층화(stratification)를 하여 구성한다. 각 층 내에서 결측값은 같은 층의 관찰자 중에서 기증자(donor)를 선택하여 기증자의 값으로 대체를 실시한다. 이 방법은 기증자를 선택하는 데 있어서 임의로 한 명 또는 여러 명의 기증자를 선택하는 랜덤 핫덱 방법보다 회귀모형의 예측력이 클수록 좋은 결과를 기대할 수 있다.

고령화연구패널조사의 대체를 실시할 때 몇 가지 특징이 발견되었고 그에 따라 대체 방법이 적절히 변형되었다. 첫 번째로 일부 소득 및 자산 항목은 응답이 거절되거나 응답 문항 간 불일치가 나타나는 경우 대괄호 질문들(unfolding brackets)을 이용하여 얻어진 부분 정보를 포함하고 있다. 두 번째로 응답자가 많지 않은 일부 문항의 경우 대괄호 질문으로부터 얻어진 부차 정보에 근거한 하위그룹(subclass)에서 기증자를 발견하지 못 한 경우가 발생하였다. 세 번째로 일부 항목의 경우 한 사람이 여러 개의 답을 제시하는 것이 가능하였고 이 경우 동일인에 의한 여러 개의 응답은 서로 연관되어 나타날 수 있으므로 연관성을 고려하여 예측이 실시되어야 한다. 네 번째로 같은 영역의 연관된 문항들 사이에 일치성(consistency)을 만족시키도록 대체가 실시될 필요가 있었다. 각각의 경우 사용된 대체 방법에 대한 자세한 설명은 KLoSA multiple imputation 보고서에서 자세히 설명되었다(송주원 외, 2007).

2. 결측값이 대체된 자료의 형태 및 구분


Multiple imputation은 한 개의 결측값에 대하여 한 개의 값으로 대체하는 대신 타당한 여러 개의 값을 가지고 대체하는 방법을 의미하는데 대체된 값들은 각각 다르므로 대체된 값이 참값과 다른 점을 모형에 반영시켜 한 개의 값을 대체하는 방법인 단일대체(single

imputation)에서 발생하는 추정량의 편의를 보정하는 것을 가능하게 한다. 본 연구에서는 각 결측값에 대하여 5개의 값을 대체하는 multiple imputation을 사용하였다. 5개의 대체된 자료를 제공하므로 single imputation에 근거한 분석을 시행하길 원하는 연구자는 대체된 자료 중 한 개의 자료 (예를 들면, 첫 번째 자료)를 선택하여 분석을 실시할 수 있다.

2.1. 대체된 자료의 형태

한 개의 자료에 multiple imputation이 적용되면 결과로서 여러 개의 결측값이 없는 대체된 자료가 만들어지게 된다. 고령화연구패널조사의 경우 5번의 대체가 이루어 졌으므로 대체된 항목들에 결측값이 없는 5개의 자료가 제공된다. 이 5개의 자료는 관찰된 값들은 모두 동일하지만 대체된 결측값은 같기도 하고 다르기도 한 형태를 가지고 있다. 결측된 자료에 대한 대체를 시행한 후 생성된 대체된 자료는 다음의 <그림 1>에 나타난 것과 같이 5개가 존재하게 되는 것이다.

<그림 1> 결측자료에 대하여 5개의 다중대체를 실시한 경우의 예



이 대체된 5개의 자료는 연구자가 분석할 수 있도록 노동연구원 고령화연구패널 홈페이지를 통해 제공된다. 제공된 자료는 대체된 변수만을 포함하므로 대체가 실시되지 않은 변수들도 포함한 분석을 실시하기 원하는 연구자는 홈페이지에 제공되는 원 자료와 결합하여 분석을 시행하면 된다. 이 때 원 자료는 대체된 변수와 동일한 이름을 지닌 대체가 시행되기 이전의 결측을 포함한 원 변수들도 포함하므로 대체된 자료를 가지고 원 변수들을 덮어씌운 후 분석을 시행해야 한다. 예를 들어 SAS를 사용하는 경우 원 자료는 w01_v10k이고 대

체된 자료는 w01_i1_v10k부터 w01_i5_v10k까지 5개의 자료이므로 각 대체된 자료를 원 자료와 결합하여 대체된 변수를 포함한 전체 자료를 만들어 분석을 시행하면 된다. 이와 같은 대체된 전체 자료를 만들기 위한 SAS program의 예제는 아래와 같다. (프로그램에서 대문자는 SAS 명령문을, 소문자는 분석자가 지정한 자료명이나 변수를 의미한다. 여기서 원 자료 및 대체된 자료명은 노동연구원에서 제공하는 자료명과 동일하게 선택하였다).

```
* 첫 번째 대체된 전체 자료 생성;
DATA w01_i1_v10k;
    MERGE w01_v10k w01_i1_v10k;
RUN;

    :

* 다섯 번째 대체된 전체 자료 생성;
DATA w01_i5_v10k;
    MERGE w01_v10k w01_i5_v10k;
RUN;
```

위의 프로그램에서 전체 변수를 포함하는 5개의 자료를 만들기 위하여 SAS의 data step을 다섯 번 써야하는 번거로움이 있으나 아래의 SAS macro를 이용하면 5개의 자료를 간단히 생성할 수 있다.

```
* Macro를 이용하여 5개의 대체된 전체 자료 생성;
%MACRO fulldata;
%DO j = 1 %TO 5;
    DATA w01_i&j_v10k;
        MERGE w01_v10k w01_i&j_v10k;
        BY pid;
    RUN;
%END;
%MEND;
%fulldata;
```

연구자는 이 자료 각각에 대하여 원하는 분석을 반복적으로 시행할 수 있다. 각 자료에 대

하여 독립적으로 분석이 시행된 후 분석 결과는 일반적으로 5개의 통계량 및 관련 분산(또는 표준 오차)으로 나타나는데 연구자는 5개의 각각 다른 통계량이 아닌 하나의 통합된 통계량을 구하는 데 목적이 있다. 각각 분석된 통계량을 통합하여 하나의 통계량을 구하는 방법은 3장에서 소개된다.

2.2. 대체된 결측값의 구분

결측값이 대체된 자료에서 어느 관찰값이 원래 관찰된 값이며 어느 관찰값이 대체된 값인지 구분을 할 수 있다면 유용할 것이다. 이 구분이 가능하다면 대체된 자료만을 가지고도 결측값의 대체없이 원 자료에 대한 분석을 실시하길 원하는 연구자는 원 관찰값 만에 근거한 분석을 시행하는 것이 가능할 것이고 대체된 자료값들이 관찰된 자료값들과 비슷한 지 여부 등의 추가 분석도 가능하다. 이를 위하여 고령화연구패널 자료의 경우 대체된 각 변수에 대하여 대체 여부를 나타내는 부속 변수인 깃발 변수(flag variable)가 추가되었다. 이 부속 변수는 원래 변수명에 _(underbar)를 추가시킨 변수명을 취한다. 예를 들어, 소득 부분의 작년 한 해 월평균 임금 소득액을 나타내는 변수 w01E003의 경우 w01E003_라는 변수가 추가되는데 이 변수는 아래와 같은 값들을 가진다.

- 0: 응답한 관찰값이 존재함
- 1: 관찰값이 모형을 통해 대체됨
- 2: *Bracket* 질문에 구간 대신 값으로 응답
- 3: 가족대표자의 응답을 가지고 대체
- : 이 문항에 대한 응답 대상자가 아님

즉, 대체 여부를 나타내는 깃발 변수(flag variable)가 값 “0”을 갖는 경우 해당 관찰값이 응답에 의하여 관찰된 값이라는 의미이며, “1”을 갖는 경우 관찰값이 결측되었으나 수정된 예측평균에 근거한 핫덱 방법에 근거하여 대체되었음을 의미한다. 한편 값 “2”는 대괄호 질문을 포함한 소득 및 자산 변수에서 응답이 구간으로 응답되지 않고 대략적인 값으로 응답된 경우 그 값으로 대체되었음을 의미하고 “3”은 가족대표자의 응답을 가지고 대체되었음을 의미한다. 일부 깃발 변수(flag variable)에서 보이는 결측값은 이 문항이 앞의 문항에 부속되어 있고 앞 문항의 응답 때문에 이 문항이 응답되지 않았음을 의미한다. 예를 들어 월평균 임금 소득액은 w01E001에서 임금 소득이 있다고 응답한 연구 대상자에게만 질문되었으므로 w01E001에서 임금소득이 없다고 응답한 경우 이 값은 결측으로 나타난다.

3. 다중대체(multiple imputation)된 자료의 분석 방법

Multiple imputation을 통해 다중대체된 자료의 경우 결측값이 없이 대체된 한 개 이상의 자료가 제공되며 이에 따른 분석은 다중대체된 각 자료의 분석 및 분석된 자료를 통합한 결과 도출의 두 단계로 나누어지게 된다.

3.1. 다중대체(multiple imputation)된 자료의 분석

다중대체된 자료 각각은 결측값이 대체되어 결측값이 없는 완전한 자료 형태를 가지고 있으므로 자료 각각에 대하여 연구목적에 알맞은 분석을 시행하면 된다. 예를 들어, 회귀분석(regression analysis)을 시행하고자 한다면 동일 관심변수에 대하여 동일 설명변수를 가지고 5개 자료 각각에 대하여 회귀분석을 실시하면 된다. 이렇게 분석을 실시하는 경우 추정된 회귀계수(regression coefficients), 표준오차(standard errors), 그리고 검정통계량(test statistics)은 5개 자료 각각으로부터 약간씩 다르게 나타나는데 이는 관심 변수가 결측되어 참값을 알지 못하는 불확실성에 근거한 차이를 나타내는 것이다. 하지만 연구자의 분석 목적은 관심 자료에 대한 5개의 서로 다른 결론이 아니라 한 개의 통합된 결론을 내리는 것이므로 5개 분석의 결과를 통합하여 한 개의 결론을 도출하기 위하여 아래의 통합 과정을 거쳐야 한다.

3.2. 분석된 자료를 통합한 결과 도출

Multiple imputation을 m 번 시행한 자료 각각에 대하여 분석을 시행한 후 얻어진 모수의 추정값들을 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 이라 하자. 또한, 이 모수의 추정된 분산을 각각 $W_1, W_2, \dots, W_m$ 이라 가정하자. 예를 들어, 회귀분석을 실시하면 i 번째 자료에 근거한 회귀 분석에서 관심 설명 변수의 회귀계수의 추정값이 $\hat{\theta}_i$ 이 되고 그 회귀계수의 표준오차의 추정값의 제곱이 W_i 가 된다. 이 경우 통합된 모수의 추정값은

$$\bar{\theta}_m = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i$$

으로 표현될 수 있다. 즉, 추정된 모수들의 평균값이 통합된 모수의 추정값이 된다.

통합된 모수의 분산의 추정값은 다음의 두 개의 분산 성분의 합으로 표현된다. 첫 번째 분산 성분은

$$\bar{W}_m = \frac{1}{m} \sum_{i=1}^m W_i$$

로서 각 모수의 추정된 분산들의 평균이다. 이 분산 성분은 대체내 분산 (within-imputation variance)으로 부른다. 두 번째 분산 성분은

$$B_m = \frac{1}{m-1} \sum_{i=1}^m (\hat{\theta}_i - \bar{\theta}_m)^2$$

으로 표현되는데 이는 각 대체된 자료의 모수의 추정값들 사이의 분산을 나타내므로 대체간 분산(between-imputation variance)이라 부른다. 통합된 모수의 분산의 추정값은

$$T_m = \overline{W}_m + \frac{m+1}{m} B_m$$

으로 구할 수 있다.

자료가 충분히 큰 경우, 이 모수에 대한 분포는 다음의 t 분포를 따른다.

$$(\theta - \bar{\theta}_m) T_m^{-1/2} \sim t_\nu,$$

여기서, t 분포의 자유도 ν 는 $\nu = (\nu_0^{-1} + \hat{\nu}_{\text{obs}}^{-1})^{-1}$ 로 계산되는데 ν_0 는

$\nu_0 = (m-1) \left(1 + \frac{1}{m+1} \frac{\overline{W}_m}{B_m} \right)^2$ 을 나타내고 $\hat{\nu}_{\text{obs}}$ 에서 ν_{com} 이 결측값이 없을 때 모수 θ 에 대한

추정의 자유도를 나타낼 때 $\hat{\nu}_{\text{obs}} = (1 - \hat{\gamma}_m) \left(\frac{\nu_{\text{com}} + 1}{\nu_{\text{com}} + 3} \right) \nu_{\text{com}}$ 을 나타낸다. 또한, 여기서 $\hat{\gamma}_m$ 은

$\hat{\gamma}_m = (1 + 1/m) B_m / T_m$ 으로서 결측에 의하여 손실된 모수 θ 에 대한 정보의 부분(fraction of information about θ missing due to nonresponse)이라 불린다. 모수의 분포가 t 분포를 따르므로 t 분포에 근거한 검정을 시행하거나 모수의 신뢰구간을 구할 수 있다. 또한 이 통합 방법은 관심 모수들에 대한 다변량 검정 및 신뢰구간의 계산 등으로의 확장도 가능하다 (Rubin, 1987).

3.3. 예제

Multiple imputation을 시행하여 만들어진 m 개의 자료들에 근거한 m 개의 분석 결과를 통합하는 과정은 연구자들이 직접 프로그램화하여 시행하기에 어려울 수 있으므로 현재 여러 가지 통계 프로그램에서는 이 결과를 통합하는 프로시저를 제공하고 있다. 예를 들어, SAS의 PROC MIANALYZE 프로시저는 위와 같이 분석된 자료의 모수들을 통합한 결과를 제공해 준다. 그 외에 무료 통계 프로그램인 R도 다중대체된 자료를 분석한 후 통합하는 함수를 제공하고 있다. 또한 Schafer(1997)가 개발한 NORM은 통계 프로그램이 필요 없이 독립적으로 시행되는 작은 크기의 프로그램으로서 위의 단계를 수행하고 통합된 결과를 제공하고 있는데 이 프로그램은 <http://www.stat.psu.edu/~jls/misoftwa.html>에서 무료로 다운받을 수 있다. 다음은 SAS에서 multiple imputation으로 대체된 여러 개의 자료를 이용한 단순 평균 계산, 층화 평균 계산, 및 회귀 분석 계수의 계산 예를 보여준다.

우선 SAS에서는 여러 개의 자료에 대하여 동일한 모형을 가지고 분석을 실시하고자 하는 경우에 여러 개의 자료를 한 개의 자료로 통합한 후 통합된 자료에 대하여 한 개의

Procedure를 이용하여 자료 별 분석을 시행하는 것이 가능하다. 이를 위하여 5개의 대체된 자료를 한 개의 자료로 통합하고 각 대체된 자료를 나타내는 변수를 가지고 각 자료를 구분하면 된다. (각 대체된 자료를 원 자료와 결합하는 프로그램은 2.1절에서 설명하였다). 제공된 대체된 자료는 몇 번째로 대체된 자료인지 나타내는 구별 변수인 w01imputation_을 가지고 있으므로 이 변수별로 분석을 시행하면 된다. 이를 위한 SAS 프로그램은 다음과 같다.

```
* 5개의 impute된 자료를 한 개의 자료로 통합;
DATA total;
  SET w01_i1_v10k w01_i2_v10k w01_i3_v10k w01_i4_v10k w01_i5_v10k;
  _imputation_=w01imputation_;
RUN;
```

여기서 새롭게 생성된 변수 _imputation_은 w01imputation_과 동일한 변수로서 각각의 자료를 분석한 후 SAS PROC MIANALYZE를 이용하여 자료를 통합하는 과정에 사용하기 위하여 생성되었다.

예제 1. 금융자산의 단순 평균 계산

```
* 각 대체 자료별 단순 평균 계산;
PROC SURVEYMEANS DATA = total;
  VAR w01f085;
  BY _imputation_;
  ODS OUTPUT STATISTICS = stat1;
RUN;

* 각 대체된 자료별로 계산된 단순 평균을 통합하여 원 자료의 단순 평균 추정;
PROC MIANALYZE DATA = stat1;
  MODELEFFECTS mean;
  STDERR stderr;
RUN;
```

SAS Procedure SURVEYMEANS에서 BY변수를 사용하여 각 대된 자료별로 금융자산의 단순평균 및 표준 오차를 계산한 후 이들 통계량들을 자료(data set)명 stat1에 저장하였다. 이 저장된 통계량들은 Procedure MIANALYZE를 사용하여 통합되었다. 이 때

MODELEFFECTS 문에는 통합할 통계량 $\hat{\theta}_i$ (여기서는, 평균)을 나타내는 변수 mean을 써 주고 STDERR문에는 W_i 의 제곱근인 평균의 표준 오차를 나타내는 stderr 변수를 써 주면 된다. Procedure MIANLYZE는 다음과 같은 결과를 제공한다.

SAS 결과 예시

The MIANLYZE Procedure					
Model Information					
Data Set		WORK.STAT			
Number of Imputations		5			
Multiple Imputation Variance Information					
Parameter	-----Variance-----			DF	
	Between	Within	Total		
mean	75.883499	1711.837134	1802.897333	1568	
Multiple Imputation Variance Information					
Parameter	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency		
mean	0.053194	0.051716	0.989763		
Multiple Imputation Parameter Estimates					
Parameter	Estimate	Std Error	95% Confidence Limits		DF
mean	1023.775585	42.460539	940.4902	1107.061	1568
Multiple Imputation Parameter Estimates					
Parameter	Minimum	Maximum	Theta0	t for H0: Parameter=Theta0	Pr > t
mean	1012.992767	1033.328748	0	24.11	<.0001

표에서 보는 바와 같이 금융자산의 단순 평균은 1023.78 MW으로 나타나고 표준편차는 42.46이다. 금융자산의 평균에 대한 95% 신뢰구간은 (940.49, 1107.06)으로 계산되어지며 금융자산이 0이라는 귀무가설은 t-통계량이 24.11, p-value가 <.0001로 5% 유의수준 하에서 유의하게 나타난다.

예제 2. 금융자산의 표본 설계 가중치를 이용한 평균 계산

이계오 등 (2006)에 설명된 표본 설계 가중치를 이용한 금융자산의 평균 추정치를 계산해 보았다.

```
* 각 대체 자료별 표본 설계 가중치를 이용한 평균 계산;
PROC SURVEYMEANS DATA = total;
    STRATA w01region1 w01region2 w01enu_type;
    CLUSTER w01enu;
    VAR w01f085;
    WEIGHT w01wgt;
    BY _imputation_;
    ODS OUTPUT STATISTICS = stat2;
RUN;

* 각 대체된 자료별로 계산된 표본 설계 가중치를 이용한 평균을 통합하여 원 자료의
증화 평균 추정;
PROC MIANALYZE DATA = stat2;
    MODELEFFECTS mean;
    STDERR stderr;
RUN;
```

SAS Procedure SURVEYMEANS에서 BY변수를 사용하여 각 대체된 자료별로 금융자산의 표본 설계 가중치를 이용한 평균 및 표준 오차를 계산한 후 이들 통계량들을 자료명 stat2에 저장하였다. 이 저장된 통계량들은 Procedure MIANALYZE를 사용하여 통합되었

다. 이 때 MODELEFFECTS 문에는 통합할 통계량 $\hat{\theta}_i$ (여기서는, 표본 설계 가중치를 이용한 평균)을 나타내는 변수 mean을 써 주고 STDERR문에는 W_i 의 제곱근인 평균의 표준 오차를 나타내는 stderr 변수를 써 주면 된다. Procedure MIANLYZE는 다음과 같은 결과를 제공한다.

SAS 결과 예시

The MIANALYZE Procedure				
Model Information				
Data Set	WORK.STAT2			
Number of Imputations	5			
Multiple Imputation Variance Information				
Parameter	-----Variance-----			DF
	Between	Within	Total	
mean	38.539587	3521.403652	3567.651157	23804
Multiple Imputation Variance Information				
Parameter	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency	
mean	0.013133	0.013046	0.997398	
Multiple Imputation Parameter Estimates				
Parameter	Estimate	Std Error	95% Confidence Limits	DF
mean	1044.266383	59.729818	927.1921 1161.341	23804
Multiple Imputation Parameter Estimates				
Parameter	Minimum	Maximum	t for H0: Theta0	Pr > t
mean	1035.807531	1050.103901	0	<.0001

표에서 보는 바와 같이 금융자산의 표본 설계 가중치를 이용한 평균은 1044.27 MW으로 나타나고 표준편차는 59.73이다. 금융자산의 표본 설계 가중치를 이용한 평균에 대한 95% 신뢰구간은 (927.19, 1161.34)로 계산되어 지며 금융자산이 0이라는 귀무가설은 t-통계량이 17.48, p-value가 <.0001로 5% 유의수준 하에서 유의하게 나타난다.

예제 3. 금융자산에 대한 회귀분석

금융자산과 성별, 연령의 관계를 나타내는 회귀모형을 적합한 분석을 시행하였다.

```
* 각 자료별 회귀 분석 실시;
PROC REG DATA=total OUTEST=outreg COVOUT;
    MODEL f085 = w01gender1 w01a001_age;
    BY _imputation_;
RUN;

* 각 자료별 회귀 분석 결과의 통합;
PROC MIANALYZE DATA=outreg;
    MODELEFFECTS Intercept w01gender1 w01a001_age;
RUN;
```

SAS Procedure REG에서 BY변수를 사용하여 각 imputed된 자료별로 회귀분석을 실시한 후 OUTEST 문을 사용하여 자료명 outreg에 회귀계수 및 회귀계수의 표준 오차 등을 저장한다. 여기에 저장된 통계량들을 Procedure MIANALYZE에서 통합하여 준다. 이 때 통합하고자 하는 통계량은 절편(intercept) 및 나이, 성별을 나타내는 두 변수의 계수, 즉 세 개의 회귀모형 모수가 되며 이를 MODELEFFECTS 문에 나타내준다. 여기서, Intercept는 변수명이 아니고 회귀모형의 절편을 의미한다. Procedure MIANLYZE는 다음과 같은 결과를 제공한다.

SAS 결과 예시

The MIANALYZE Procedure					
Model Information					
Data Set		WORK.OUTREG			
Number of Imputations		5			
Multiple Imputation Variance Information					
Parameter	-----Variance-----			DF	
	Between	Within	Total		
Intercept	890.090253	66955	68024	16224	
w01gender1	29.573442	427.272480	462.760610	680.15	
w01a001_age	0.538980	16.850509	17.497284	2927.5	
Multiple Imputation Variance Information					
Parameter	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency		
Intercept	0.015953	0.015823	0.996845		
w01gender1	0.083057	0.079391	0.984370		
w01a001_age	0.038383	0.037622	0.992532		
Multiple Imputation Parameter Estimates					
Parameter	Estimate	Std Error	95% Confidence Limits		DF
Intercept	2127.827592	260.813283	1616.605	2639.050	16224
w01gender1	-103.215014	21.511871	-145.453	-60.977	680.15
w01a001_age	-13.240722	4.182976	-21.443	-5.039	2927.5
Multiple Imputation Parameter Estimates					
Parameter	Minimum	Maximum	t for H0:		
			Theta0	Parameter=Theta0	Pr > t
Intercept	2081.400933	2164.672953	0	8.16	<.0001
w01gender1	-111.891438	-97.829171	0	-4.80	<.0001
w01a001_age	-14.074498	-12.248854	0	-3.17	0.0016

표에서 보는 바와 같이 회귀 모형의 절편(intercept)은 2127.83, 성별(w01gender1)과 나이(w01a001_age)의 회귀 계수는 각각 -103.22와 -13.24로 나타나며, 절편을 포함한 세 회귀모수의 표준오차는 각각 260.81, 21.51, 4.18로 추정된다. 절편 및 각 변수의 회귀 계수가 0인가를 검정하는 t-통계량은 각각 8.16, -4.80, -3.17로서 모두 5% 유의수준 하에서 통계적으로 유의하게 나타난다.

참고문헌

- 이계오, 김영원, 장지연 (2006) 고령화연구패널조사의 표본설계 연구, 노동연구원.
- Bell R. (1999) Depression PORT Methods Workshop (I). RAND: Santa Monica, CA.
- Little R. J. A. (1988), "Missing data adjustments in large surveys," *Journal of Business and Economic Statistics*, 6, 287-301.
- Rubin D.B. (1987) *Multiple Imputation for Nonresponse in Surveys*, John Wiley: New York.
- Schafer, J.L. (1997) *Analysis of Incomplete Multivariate Data*, Chapman and Hall, London, UK.
- Song, J., Lee S. Y., Yoon, C., Yoon, R., Song, K-H., Kim, B., Chang, J., and Lee, H. (2007) *KLoSA Report*, Korea Labor Institute.