

KL_oSA USER GUIDE

고령화연구패널 2차 조사 자료에서 발생하는
결측값에 대한 다중대체

- 대체된 자료의 분석 -

고령화연구패널조사는 고령화 시대에 대비하기 위하여 한국의 고령자 모집단에 대한 실태를 파악하고 기초 자료를 수집하기 위하여 계획되었고 1차 조사가 2006년에, 그리고 제 1차 추적조사인 2차 조사가 2008년에 실시되었다. 2007년에는 1차 조사 자료에서 발생하는 결측값에 대하여 소득 및 자산 변수를 중심으로 한 다중대체(multiple imputation)가 시행되었고 2008년 시행된 2010년에는 2차 조사에서 발생하는 결측값에 대하여 소득 및 자산 변수를 중심으로 한 다중대체가 시행되었다. 본 User Guide는 2010년 시행된 다중대체를 통하여 생성된 대체(impute)된 자료에 대한 사용자들의 이해를 돕고자 쓰여 졌다. 1장에서는 우선 다중대체를 실시할 때 사용된 대체 모형에 대하여 간략히 설명하고 2장에서는 대체된 자료의 형태 및 자료에서 원래 관찰된 값과 대체된 값을 구별하는 방법에 대하여 설명한다. 3장에서는 대체된 자료를 사용하여 분석을 시행하는 방법에 관하여 설명한다. 대체 모형에 대한 자세한 설명 및 결과 비교는 KLoSA 2차 자료에 대한 다중대체 결과 보고서(report) (송주원 외, 2010)에 나타난다.

1. 결측값 대체 방법

고령화연구패널조사의 경우 대부분의 변수에서 결측값(missing data)의 비율이 5%미만으로 작게 나타났으나 자산 일부 항목에서 결측값의 비율은 10 ~ 20% 내외까지 증가하였으며 일부 응답자가 많지 않은 항목의 경우 40% 정도까지 나타났다. 따라서 결측값을 포함한 변수에 대한 적절한 분석을 위하여 결측이 발생한 주요 항목에 대하여 다중대체(multiple imputation)가 실시되었는데 특히 결측 비율이 높은 소득 및 자산 항목의 대체에 중점을 두고 진행되었다. 각 변수별 결측 비율이 거의 대부분의 변수에서 20% 미만으로 나타났으므로 대체 자료의 개수는 1차와 마찬가지로 5개로 결정하였다.

고령화연구패널조사는 전체 8개의 영역(session)으로 구성되어 있는데 결측값의 대체가 결측 비율이 높은 소득 및 자산 항목의 대체에 중점을 두고 진행되었지만 관련된 주요 변수들의 대체도 함께 실시되었다. 우선 인구영역의 주요 변수들이 5번 대체되었고 대체된 5개의 자료 각각에 대하여 주요 인구영역 변수 및 디자인 변수(design variables)들을 설명 변수로 사용하여 건강 영역 주요 변수의 대체를 실시하였다. 이렇게 대체된 5개 자료 각각에 근거하여 관련 변수를 설명 변수로 사용한 고용 영역의 현재 고용 및 퇴직 소득에 관한 대체를 실시하였다. 다음으로 각 대체된 자료에서 소득과 관련된 변수들을 설명 변수로 사용하여 소득 영역의 주요 소득 항목들에 대한 대체가 실시되었다. 이 때 자산 영역의 집 소유 여부 및 금융자산 총액도 설명변수로 포함되어 소득과 자산의 연관성을 설명하고자 하였다. 소득영역이 대체된 후 대체된 각 개인당 총소득을 계산한 후 다른 관련 변수들과 함께 설명 변수로 설정하여 주요 자산 영역 변수들에 대한 대체를 실시하였다. 마지막으로 가족대표자만이 응답한 가족 영역 중 자녀의 수 및 자녀들에게서 지원받은 액수 및 지원한 액수에 관

한 항목들을 대체하였다. 이 때, 결측이 발생한 변수의 1차년도 응답값을 설명변수로 포함시켜 설명력을 증가시킴으로써 보다 정확한 예측값을 구할 수 있었을 것으로 기대된다. 만약 1차 조사 시 응답값이 결측인 경우 1차 년도 대체된 자료의 값을 설명 변수로 사용하였다. 즉, 1차 조사의 대체된 5개의 자료 각각을 설명 변수로 사용하여 2차 조사의 대체 자료 5개를 생성하였다. 대체 모형에 사용된 설명 변수에 관한 자세한 정보는 KLoSA 2차 자료에 대한 다중대체 결과 보고서에 기술되어 있다(송주원 외, 2010).

2006년에 실시된 고령화연구패널 제 1차년도 조사의 무응답 대체에서는 수정된 평균에 근거한 핫덱대체 방법을 사용하여 다중대체를 실시하였다. 이 방법은 Little(1988)이 제안한 일종의 핫덱대체(hotdeck imputation) 방법으로서 미국 RAND의 Bell(1999)이 SAS Macro로 프로그램화하여 여러 가지 조사 연구에 적용해 왔다. 고령화연구패널 제 1차년도 자료에 대한 모의실험에서 이 방법은 다른 여러 가지 대체법에 비하여 상대적으로 우수한 결과를 보였다. 따라서 고령화연구패널 2차 추적 조사에서 발생한 결측값도 이 모형을 사용하여 대체를 실시하였고 모의실험을 실시하여 이 모형의 적절함을 확인하였다. 이 방법은 결측이 발생한 자료값을 자료 내 관찰된 값 들 중 하나 또는 여러 개의 값을 가지고 대체시키는 일종의 핫덱대체법이지만 관찰값 중 하나 또는 여러 개의 값을 임의로 선택하는 랜덤 핫덱(random hotdeck) 대신 자료를 비슷한 여러 개의 하위 그룹(subclass)으로 나누어 같은 하위 그룹 내에서 핫덱대체를 실시한다. 이 때 하위그룹은 결측이 발생한 변수에 대하여 관찰된 자료만을 대상으로 회귀모형(regression model)을 적합하여 결측이 포함된 모든 자료에 대한 예측값을 구한 후 예측값에 근거하여 층화(stratification)하여 구성한다. 각 층 내에서 결측값은 같은 층의 관찰자 중에서 기증자(donor)를 선택하여 기증자의 값으로 대체를 실시한다. 이 방법은 기증자를 선택하는 데 있어서 임의로 한 명 또는 여러 명의 기증자를 선택하는 랜덤 핫덱 방법보다 회귀모형의 예측력이 클수록 좋은 결과를 기대할 수 있다.

고령화연구패널 1차 조사에 대한 대체(imputation)를 실시할 때 자료의 특성에 따라 대체 방법이 적절히 변형되었다. 첫 번째로 일부 소득 및 자산 항목은 응답이 거절되거나 응답 문항들 사이에 불일치가 나타나는 경우 대괄호 질문들(unfolding brackets)을 이용하여 얻어진 부분 정보를 포함하고 있으므로 이 정보를 사용하여 대체를 실시하였다. 두 번째로 응답자가 많지 않은 일부 문항의 경우 대괄호 질문으로부터 얻어진 부차 정보에 근거한 하위그룹(subclass)에서 기증자를 발견하지 못하는 경우가 발생하였고 이 경우 회귀모형을 사용한 대체가 실시되었다. 세 번째로 일부 항목의 경우 한 사람이 여러 개의 답을 제시하는 것이 가능하였고 이 경우 동일인에 의한 여러 가지 응답값은 서로 연관되어 나타날 수 있으므로 연관성을 고려하여 대체가 실시되었다. 네 번째로 같은 영역 내의 연관된 문항들 사이에 일치성(consistency)이 존재하면 이를 만족시키도록 대체가 실시되었다. 이 특징들은 고령화연구패널 2차 조사의 대체를 실시할 때도 동일하게 고려하여 1차 자료와 2차 자료 간 대체 방법의 일관성을 유지하였다. 그 외에 2차 자료의 대체 시에는 범주형 변수 일부에서 결측이

발생하였고 이를 고려하여 모형을 확장하였다. 각각의 경우 사용된 대체 방법에 대한 자세한 설명은 KLoSA 2차 자료에 대한 다중대체 결과 보고서에서 자세히 설명되어 있다(송주원 외, 2010).


2. 결측값이 대체된 자료의 형태 및 구분

다중대체(multiple imputation)는 한 개의 결측값에 대하여 한 개의 값으로 대체하는 대신 타당한 여러 개의 값을 가지고 대체하는 방법을 의미하는데 대체된 값들은 각각 다르므로 대체된 값이 참값과 다르다는 점을 모형에 반영시켜 한 개의 값을 대체하는 방법인 단일대체(single imputation)에서 발생하는 분산추정량의 과소추정 문제를 보정하는 것을 가능하게 한다. 본 연구에서는 각 결측값에 대하여 5개의 값을 대체하는 다중대체를 실시하였다. 5개의 대체된 자료를 제공하고 각각의 자료는 단일대체된 자료이므로 단일대체에 근거한 분석을 시행하길 원하는 연구자는 대체된 자료 중 한 개의 자료(예를 들면, 첫 번째 자료)를 임의로 선택하여 분석을 실시할 수 있다.

2.1. 대체된 자료의 형태

한 개의 결측값을 포함한 자료에 다중대체를 실시하면 그 결과로서 여러 개의 결측값이 없는 대체된 자료가 만들어지게 된다. 고령화연구패널조사의 경우 5번의 대체가 이루어 졌으므로 대체된 항목들에 결측값이 없는 5개의 자료가 제공된다. 이 5개의 자료는 관찰된 값들은 모두 동일하지만 대체된 결측값은 같기도 하고 다르기도 한 형태를 가지고 있다. 결측된 자료에 대한 대체를 시행한 후 생성된 대체된 자료는 다음의 <그림 2.1>에 나타난 것과 같이 5개가 존재하게 되는 것이다. 이 대체된 5개의 자료는 연구자가 분석할 수 있도록 노동연구원 고령화연구패널 홈페이지를 통해 제공된다. 제공된 자료는 대체된 변수만을 포함하므로 대체가 실시되지 않은 변수들도 포함한 분석을 실시하기 원하는 연구자는 홈페이지에 제공되는 원 자료와 결합하여 분석을 시행하면 된다. 이 때 원 자료는 대체된 변수와 동일한 이름을 지닌 대체가 시행되기 이전의 결측을 포함한 원 변수들도 포함하므로 대체된 자료를 가지고 원 변수들을 덮어씌운 후 분석을 시행해야 한다. 예를 들어 SAS를 사용하는 경우 원 자료는 w02_main_v10k이고 대체된 자료는 w02_i1_v10k부터 w02_i5_v10k까지 5개의 자료이므로 각 대체된 자료를 원 자료와 결합하여 대체된 변수를 포함한 전체 자료를 만들어 분석을 시행하면 된다(모든 자료는 pid08의 크기순으로 배열되어 있다고 가정한다). 대체된 전체 자료를 만들기 위한 SAS program의 예제는 아래와 같다. (프로그램에서 대문자는 SAS 명령문을, 소문자는 분석자가 지정한 자료명이나 변수를 의미한다. 여기서 원 자료 및 대체된 자료명은 노동연구원에서 제공하는 자료명과 동일하게 선택하였다).

<그림 2.1> 결측자료에 대하여 5개의 다중대체를 실시한 경우의 예



```

* 첫 번째 대체된 전체 자료 생성;
DATA w02_i1_v10k;
    MERGE w02_main_v10k w02_i1_v10k;
    BY pid08;
RUN;

    ⋮

* 다섯 번째 대체된 전체 자료 생성;
DATA w02_i5_v10k;
    MERGE w02_main_v10k w02_i5_v10k;
    BY pid08;
RUN;
    
```

위의 프로그램에서 전체 변수를 포함하는 5개의 자료를 만들기 위하여 SAS의 data step을

다섯 번 써야하는 번거로움이 있으나 아래의 SAS macro를 이용하면 5개의 자료를 간단히 생성할 수 있다.

```
* Macro를 이용하여 5개의 대체된 전체 자료 생성;
%MACRO fulldata;
%DO j = 1 %TO 5;
    DATA w02_i&j._v10k;
        MERGE w02_main_v10k w02_i&j._v10k;
        BY pid08;
    RUN;
%END;
%MEND;
%fulldata;
```

연구자는 이 자료 각각에 대하여 원하는 분석을 반복적으로 시행할 수 있다. 각 자료에 대하여 독립적으로 분석이 시행된 후 분석 결과는 일반적으로 5개의 통계량 및 관련 분산(또는 표준 오차)으로 나타나는데 연구자는 5개의 각각 다른 통계량이 아닌 하나의 통합된 통계량을 구하는 데 목적이 있다. 각각 분석된 통계량을 통합하여 하나의 통계량을 구하는 방법은 3장에서 소개된다.

2.2. 대체된 결측값의 구분

결측값이 대체된 자료에서 어느 관찰값이 원래 관찰된 값이며 어느 관찰값이 대체된 값인지 구분을 할 수 있다면 유용할 것이다. 이 구분이 가능하다면 대체된 자료만을 가지고도 결측값의 대체없이 원 자료에 대한 분석을 실시하길 원하는 연구자는 원 관찰값 만에 근거한 분석을 시행하는 것이 가능할 것이고 대체된 자료값들이 관찰된 자료값들과 비슷한 지 여부 등의 추가 분석도 가능하다. 이를 위하여 고령화연구패널 자료의 경우 대체된 각 변수에 대하여 대체 여부를 나타내는 부속 변수인 깃발 변수(flag variable)가 추가되었다. 이 부속 변수는 원래 변수명에 _(underbar)를 추가시킨 변수명을 취한다. 예를 들어, 소득 부분의 작년 한 해 월평균 임금 소득액을 나타내는 변수 w02E003의 경우 w02E003_라는 변수가 추가되는데 이 변수는 아래와 같은 값들을 가진다.

- 0: 응답한 관찰값이 존재함
- 1: 관찰값이 모형을 통해 대체됨
- 2: *Bracket* 질문에 구간 대신 값으로 응답
- 3: 가족대표자의 응답을 가지고 대체
- : 이 문항에 대한 응답 대상자가 아님

즉, 대체 여부를 나타내는 깃발 변수(flag variable)가 값 “0”을 갖는 경우 해당 관찰값이 응답에 의하여 관찰된 값이라는 의미이며, “1”을 갖는 경우 관찰값이 결측되었으나 수정된 예측평균에 근거한 핫덱 방법에 근거하여 대체되었음을 의미한다. 한편 값 “2”는 대괄호 질문을 포함한 소득 및 자산 변수에서 응답이 구간으로 응답되지 않고 대략적인 값으로 응답된 경우 그 값으로 대체되었음을 의미하고, “3”은 가족대표자의 응답을 가지고 대체되었음을 의미한다. 일부 깃발 변수(flag variable)에서 보이는 결측값은 이 문항이 앞의 문항에 부속되어 있고 앞 문항의 응답 때문에 이 문항이 응답되지 않았음을 의미한다. 예를 들어 월평균 임금 소득액은 w02E001에서 임금 소득이 있다고 응답한 패널에게만 질문되었으므로 w02E001에서 임금소득이 없다고 응답한 경우 w02E001_의 해당 패널의 값은 결측으로 나타난다.

3. 다중대체(multiple imputation)된 자료의 분석 방법

다중대체된 자료의 경우 결측값이 없이 대체된 한 개 이상의 자료가 제공되며 이에 따른 분석은 다중대체된 각 자료의 분석 및 분석된 자료를 통합한 결과 도출의 두 단계로 나누어지게 된다.

3.1. 다중대체(multiple imputation)된 자료의 분석

다중대체된 자료 각각은 결측값이 대체되어 결측값이 없는 완전한 자료 형태를 가지고 있으므로 자료 각각에 대하여 연구목적에 알맞은 분석을 시행하면 된다. 예를 들어, 회귀분석(regression analysis)을 시행하고자 한다면 동일 관심변수에 대하여 동일 설명변수를 가지고 5개 자료 각각에 대하여 회귀분석을 실시하면 된다. 이렇게 분석을 실시하는 경우 추정된 회귀계수(regression coefficients), 표준오차(standard errors), 그리고 검정통계량(test statistics)은 5개 자료 각각으로부터 약간씩 다르게 나타나는데 이는 관심 변수가 결측되어 참값을 알지 못하는 불확실성에 근거한 차이를 나타내는 것이다. 하지만 연구자의 분석 목적은 관심 자료에 대한 5개의 서로 다른 결론이 아니라 한 개의 통합된 결론을 내리는 것이므로 5개 분석의 결과를 통합하여 한 개의 결론을 도출하기 위하여 아래의 통합 과정을 거쳐야 한다.

3.2. 분석된 자료를 통합한 결과 도출

다중대체를 m 번 시행한 자료 각각에 대하여 분석을 시행한 후 얻어진 모수의 추정값들을 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 이라 하자. 또한, 이 모수의 추정된 분산을 각각 $W_1, W_2, \dots, W_m$ 이라 가정하자. 예를 들어, 회귀분석을 실시하면 i 번째 자료(이 때, $i = 1, 2, \dots, m$)에 근거한 회귀 분석에서 관심 설명 변수의 회귀계수의 추정값이 $\hat{\theta}_i$ 이 되고 그 회귀계수의 표준오차의 추정값의 제곱이 W_i 가 된다. 이 경우 통합된 모수의 추정값은

$$\overline{\theta}_m = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i$$

으로 표현될 수 있다. 즉, 추정된 모수들의 평균값이 통합된 모수의 추정값이 된다.

통합된 모수의 분산의 추정값은 다음의 두 개의 분산 성분의 합으로 표현된다. 첫 번째 분산 성분은

$$\overline{W}_m = \frac{1}{m} \sum_{i=1}^m W_i$$

로서 각 모수의 추정된 분산들의 평균이다. 이 분산 성분은 대체내 분산(within-imputation variance)으로 부른다. 두 번째 분산 성분은

$$B_m = \frac{1}{m-1} \sum_{i=1}^m (\hat{\theta}_i - \overline{\theta}_m)^2$$

으로 표현되는데 이는 각 대체된 자료의 모수의 추정값들 사이의 분산을 나타내므로 대체간 분산(between-imputation variance)이라 부른다. 통합된 모수의 분산의 추정값은

$$T_m = \overline{W}_m + \frac{m+1}{m} B_m$$

으로 구할 수 있다.

자료가 충분히 큰 경우, 이 모수에 대한 분포는 다음의 t -분포를 따른다.

$$(\theta - \overline{\theta}_m) T_m^{-\frac{1}{2}} \sim t_\nu,$$

여기서, t -분포의 자유도 ν 는 $\nu = (\nu_0^{-1} + \widehat{\nu}_{obs}^{-1})^{-1}$ 로 계산되는데 이 때 ν_0 는 $\nu_0 = (m-1) \left(1 + \frac{1}{m+1} \frac{\overline{W}_m}{B_m} \right)^2$ 을 나타내고 $\widehat{\nu}_{obs} = (1 - \widehat{\gamma}_m) \left(\frac{\nu_{com} + 1}{\nu_{com} + 3} \right) \nu_{com}$ 으로 나타나는데 이 때 ν_{com} 은 결측값이 없을 때 모수 θ 에 대한 추정의 자유도를 나타낸다. 또한, $\widehat{\gamma}_m = \left(1 + \frac{1}{m} \right) \frac{B_m}{T_m}$ 으로서 무응답으로 인하여 손실된 모수 θ 에 대한 정보량이라 불린다. 모수의 분포가 t -분포를 따르므로 t -분포에 근거한 검정을 시행하거나 모수의 신뢰구간을 구할 수 있다. 또한 이 통합 방법은 관심 모수들에 대한 다변량 검정 및 신뢰구간의 계산 등

으로의 확장도 가능하다 (Rubin, 1987).

3.3. 예제

다중대체를 시행하여 만들어진 m 개의 자료들에 근거한 m 개의 분석 결과를 통합하는 과정은 일반 연구자들이 직접 프로그램화하여 시행하기에 어려울 수 있으므로 현재 여러 가지 통계 프로그램에서는 이 결과를 통합하는 프로시저를 제공하고 있다. 예를 들어, SAS의 PROC MIANALYZE 프로시저는 위와 같이 분석된 자료의 모수들을 통합한 결과를 제공해 준다. 그 외에 무료 통계 분석 프로그램인 R도 다중대체된 자료를 분석한 후 통합하는 함수를 제공하고 있다. 또한 Schafer(1997)가 개발한 독립 프로그램 NORM은 통계분석 프로그램과의 연동없이 독립적으로 시행되는 작은 크기의 프로그램으로서 위의 단계를 수행하고 통합된 결과를 제공하는데 이 프로그램은 <http://www.stat.psu.edu/~jls/misoftwa.html>에서 무료로 다운받을 수 있다. 다음은 SAS에서 다중대체된 여러 개의 자료를 이용한 단순 평균 계산, 층화 평균 계산, 및 회귀 분석 계수의 계산 예를 보여준다.

우선 SAS에서는 여러 개의 자료에 대하여 동일한 모형을 가지고 분석을 실시하고자 하는 경우에 여러 개의 자료를 한 개의 자료로 통합한 후 통합된 자료에 대하여 한 개의 Procedure를 이용하여 자료 별 분석을 시행하는 것이 가능하다. 이를 위하여 5개의 대체된 자료를 한 개의 자료로 통합하고 각 대체된 자료를 나타내는 변수를 가지고 각 자료를 구분하면 된다(각 대체된 자료를 원 자료와 결합하는 프로그램은 2.1절에서 설명하였다). 제공된 대체된 자료는 몇 번째로 대체된 자료인지 나타내는 구별 변수인 w02imputation_을 가지고 있으므로 이 변수별로 분석을 시행하면 된다. 이를 위한 SAS 프로그램은 다음과 같다.

* 5개의 impute된 자료를 한 개의 자료로 통합;

```
DATA total;
```

```
SET w02_i1_v10k w02_i2_v10k w02_i3_v10k w02_i4_v10k w02_i5_v10k;
```

```
_imputation_=w02imputation_;
```

```
RUN;
```

여기서 새롭게 생성된 변수 _imputation_은 w02imputation_과 동일한 변수로서 각각의 자료를 분석한 후 SAS PROC MIANALYZE를 이용하여 자료를 통합하는 과정에 사용하기 위하여 생성되었다.

예제 1. 금융자산의 단순 평균 계산

```

* 각 대체 자료별 단순 평균 계산;
PROC SURVEYMEANS DATA = total;
  VAR w02f085;
  BY _imputation_;
  ODS OUTPUT STATISTICS = stat1;
RUN;

* 각 대체된 자료별로 계산된 단순 평균을 통합하여 원 자료의 단순 평균 추정;
PROC MIANALYZE DATA = stat1;
  MODELEFFECTS mean;
  STDERR stderr;
RUN;

```

<그림 3.1> 금융자산 단순 평균 계산 SAS Output

The MIANALYZE Procedure					
Model Information					
Data Set	WORK.STAT1				
Number of Imputations	5				
Multiple Imputation Variance Information					
Parameter	-----Variance-----			DF	
	Between	Within	Total		
mean	221.823061	4354.111277	4620.298951	1205.1	
Multiple Imputation Variance Information					
Parameter	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency		
mean	0.061135	0.059173	0.988304		
Multiple Imputation Parameter Estimates					
Parameter	Estimate	Std Error	95% Confidence Limits	DF	
mean	1228.257040	67.972781	1094.899 1361.615	1205.1	
Multiple Imputation Parameter Estimates					
Parameter	Minimum	Maximum	Theta0	t for H0: Parameter=Theta0	Pr > t
mean	1212.871470	1247.019020	0	18.07	<.0001

SAS Procedure SURVEYMEANS에서 BY변수를 사용하여 각 대된 자료별로 금융자산의 단순평균 및 표준 오차를 계산한 후 이들 통계량들을 자료(data set)명 stat1에 저장하였다. 이 저장된 통계량들은 Procedure MIANALYZE를 사용하여 통합되었다. 이 때 MODELEFFECTS 문에는 통합할 통계량 $\hat{\theta}_i$ (여기서는, 평균)을 나타내는 변수 mean을 써 주고 STDERR문에는 W_i 의 제곱근인 평균의 표준 오차를 나타내는 stderr 변수를 써 주면 된다. Procedure MIANLYZE는 <그림 3.1>과 같은 결과를 제공한다. 금융자산의 단순 평균은 1228.26 MW으로 나타나고 표준편차는 67.97이다. 금융자산의 평균에 대한 95% 신뢰구간은 (1094.90, 1361.62)로 계산되어 지며 금융자산이 0이라는 귀무가설은 t -통계량이 18.07, p-value가 <.0001로 5% 유의수준 하에서 유의하게 나타난다.

예제 2. 금융자산의 표본 설계 가중치를 이용한 평균 계산

이계오(2009)에 설명된 표본 설계 가중치를 이용한 금융자산의 평균 추정치를 계산해 보았다.

```
* 층화변수 생성;
DATA total; SET total;
    strata=compress(w02region1)||compress(w02region2)||compress(w02enu_type);
RUN;

* 각 대체 자료별 표본 설계 가중치를 이용한 평균 계산;
PROC SURVEYMEANS DATA = total;
    STRATA strata;
    VAR w02f085;
    WEIGHT w02wgt02;
    BY _imputation_;
    ODS OUTPUT STATISTICS = stat2;
RUN;

* 각 대체된 자료별로 계산된 표본 설계 가중치를 이용한 평균을 통합하여 원 자료의
층화 평균 추정;
PROC MIANALYZE DATA = stat2;
    MODELEFFECTS mean;
    STDERR stderr;
RUN;
```

<그림 3.2> 금융자산 표본 설계 가중치를 이용한 평균 계산 SAS Output

The MIANALYZE Procedure				
Model Information				
Data Set		WORK.STAT2		
Number of Imputations		5		
Multiple Imputation Variance Information				
Parameter	-----Variance-----			DF
	Between	Within	Total	
mean	144.700274	6094.662430	6268.302759	5212.7
Multiple Imputation Variance Information				
Parameter	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency	
mean	0.028491	0.028074	0.994417	
Multiple Imputation Parameter Estimates				
Parameter	Estimate	Std Error	95% Confidence Limits	DF
mean	1262.881057	79.172614	1107.670 1418.093	5212.7
Multiple Imputation Parameter Estimates				
Parameter	Minimum	Maximum	t for H0: Theta0	Pr > t
mean	1250.056623	1278.971294	0 15.95	<.0001

표본설계에서 시도(w02region1), 동부/읍면부(w02region2), 주택유형(w02enu_type)을 층화변수로 사용하였으므로 SAS 분석을 위해 compress 함수를 사용하여 각 변수 값의 공백을 없애주고 ||을 사용하여 세 변수의 값들을 이어줌으로써 층화변수 strata를 생성하였다. 이 예제에서는 이계오(2009) 예제와 같이 층화변수 만을 고려하였지만 1차년도 자료의 조사구 변수(w01enu)를 사용하여 CLUSTER 문을 포함한 분석을 시행할 수도 있다.

SAS Procedure SURVEYMEANS에서 BY변수를 사용하여 각 대체된 자료별로 금융자산의 표본 설계 가중치를 이용한 평균 및 표준 오차를 계산한 후 이들 통계량들을 자료명 stat2에 저장하였다. 이 저장된 통계량들은 Procedure MIANALYZE를 사용하여 통합되었다. 이때 MODELEFFECTS 문에는 통합할 통계량 $\hat{\theta}_i$ (여기서는, 표본 설계 가중치를 이용한 평균)을 나타내는 변수 mean을 써 주고 STDERR문에는 W_i 의 제곱근인 평균의 표준 오차를 나타내는 stderr 변수를 써 주면 된다. Procedure MIANLYZE는 <그림 3.2>와 같은 결과를 제공한다.

금융자산의 표본 설계 가중치를 이용한 평균은 1262.88 MW으로 나타나고 표준편차는 79.17이다. 금융자산의 표본 설계 가중치를 이용한 평균에 대한 95% 신뢰구간은

(1107.67, 1418.09)로 계산되어 지며 금융자산이 0이라는 귀무가설은 t -통계량이 15.95, p -value가 <.0001로 5% 유의수준 하에서 유의하게 나타난다.

예제 3. 금융자산에 대한 회귀분석

금융자산과 성별, 연령의 관계를 나타내는 회귀모형을 적합한 분석을 시행하였다.

```
* 2차년도 현재 연령 계산;
DATA w01_v12k; SET w01_v12k;
    KEEP pid w01a001_Age;
RUN;
PROC SORT DATA=total;
    BY pid;
RUN;
DATA total1; MERGE total(in=in1) w01_v12k;
    BY pid;
    IF in1;
    IF w02A001 = 1 THEN w02age = w01a001_age + 2;
    IF w02A001 = 5 THEN w02age = 2008-w02A002y;
RUN;
PROC SORT DATA=total1;
    BY _imputation_ pid08;
RUN;

* 각 자료별 회귀 분석 실시;
PROC REG DATA=total OUTEST=outreg COVOUT;
    MODEL w02f085 = w02gender1 w02age;
    BY _imputation_;
RUN;

* 각 자료별 회귀 분석 결과의 통합;
PROC MIANALYZE DATA=outreg;
    MODELEFFECTS Intercept w02gender1 w02age;
RUN;
```

2차 자료에서는 1차 자료(w01_v12k.sas7bdat)에서 응답한 연령에 대한 확인을 거쳐 연령

이 잘못 응답된 경우만 수정하였으므로 1차 자료의 연령 응답이 정확한 경우 1차 자료의 응답 연령에 2를 더하고 1차 자료의 연령 응답이 부정확한 경우 2차 자료의 수정된 연령 정보를 이용하였다. 이렇게 생성된 변수는 w02age이다.

SAS Procedure REG에서 BY변수를 사용하여 각 imputed된 자료별로 회귀분석을 실시한 후 OUTEST 문을 사용하여 자료명 outreg에 회귀계수 및 회귀계수의 표준 오차 등을 저장한다. 여기에 저장된 통계량들을 Procedure MIANALYZE에서 통합하여 준다. 이 때 통합하고자 하는 통계량은 절편(intercept) 및 나이, 성별을 나타내는 두 변수의 계수, 즉 세 개의 회귀모형 모수가 되며 이를 MODELEFFECTS 문에 나타내준다. 여기서, Intercept는 변수명이 아니고 회귀모형의 절편을 의미한다. Procedure MIANLYZE는 <그림 3.3>과 같은 결과를 제공한다.

<그림 3.3> 금융자산 회귀분석 SAS Output

The MIANALYZE Procedure					
Model Information					
Data Set			WORK.OUTREG		
Number of Imputations			5		
Multiple Imputation Variance Information					
Parameter	-----Variance-----			DF	
	Between	Within	Total		
Intercept	122.595195	187543	187690	6.51E6	
w02gender1	30.551110	1103.890668	1140.551999	3871.5	
w02age	0.052628	43.370934	43.434087	1.89E6	
Multiple Imputation Variance Information					
Parameter	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency		
Intercept	0.000784	0.000784	0.999843		
w02gender1	0.033211	0.032643	0.993514		
w02age	0.001456	0.001455	0.999709		
Multiple Imputation Parameter Estimates					
Parameter	Estimate	Std Error	95% Confidence Limits		DF
Intercept	2393.721139	433.232233	1544.601	3242.841	6.51E6
w02gender1	-109.420725	33.772059	-175.633	-43.208	3871.5
w02age	-13.236982	6.590454	-26.154	-0.320	1.89E6
Multiple Imputation Parameter Estimates					
Parameter	Minimum	Maximum	t for H0:		
			Theta0	Parameter=Theta0	Pr > t
Intercept	2384.954213	2412.581441	0	5.53	<.0001
w02gender1	-114.811754	-101.040600	0	-3.24	0.0012
w02age	-13.503984	-12.904216	0	-2.01	0.0446

회귀 모형의 절편(intercept)은 2393.72, 성별(w01gender1)과 나이(w01a001_age)의 회귀 계수는 각각 -109.42와 -13.24로 나타나며, 절편을 포함한 세 회귀모수의 표준오차는 각각 433.23, 33.77, 6.59로 추정된다. 절편 및 각 변수의 회귀 계수가 0인가를 검정하는 t -통계량은 각각 5.53, -3.24, -2.01로서 모두 5% 유의수준 하에서 통계적으로 유의하게 나타난다.

참고문헌

- 송주원, 임화경, 육태미, 윤라헬, 신성원, 강승희, 윤초롱 (2010) “KLoSA Report: 고령화연구패널 2차 조사 자료에서 발생하는 결측값에 대한 다중대체”, 한국노동연구원.
- 이계오 (2009) 고령화연구패널조사 2차년도(WAVE I) 가중치, 고령화연구패널보고서, 노동연구원.
- Bell R. (1999) Depression PORT Methods Workshop (I). RAND: Santa Monica, CA.
- Little R. J. A. (1988), “Missing data adjustments in large surveys,” *Journal of Business and Economic Statistics*, 6, 287-301.
- Rubin D.B. (1987) *Multiple Imputation for Nonresponse in Surveys*, John Wiley: New York.
- Schafer, J.L. (1997) *Analysis of Incomplete Multivariate Data*, Chapman and Hall, London, UK.