

고령화연구패널 1~7차 자료 무응답 대체값 산출을 위한

다중대체 안내서

한국고용정보원

Korea Employment Information Service



1. 다중 대체법

다중 대체 방법은 원표본의 결측값을 한 번 이상 대체하여 여러 개 ($D \geq 2$)의 대체된 표본을 구하는 방법이다. 다중 대체 방법은 Rubin (1978)에 의해 처음 소개되었고 이후 Rubin (1987a)의 책에서 자세하게 다루어졌다. 현재는 단일 대체방법에서 발생하는 대체에 의한 불확실성을 고려하는 방법으로 여러 분야에서 사용되고 있다. 다중 대체법은 D 개의 대체된 표본을 만들어야 하므로 항상 같은 값으로 결측자료를 대체할 수 없다. 그러므로 각 표본은 결측자료의 예측분포 또는 사후분포에서 추출된 값으로 결측값을 대체하는 방법이 자연스럽다. 이런 이유로 다중 대체방법은 베이지안 방법을 이용하는 것이 적절하다고 알려져 있다. 이렇게 같은 예측분포로부터 대체값을 구하여 D 개의 대체 표본을 구하게 되면 이 D 개의 대체 표본으로부터 원하는 분석을 각 각 수행하여 모수 θ 의 점추정치와 표준오차의 추정치를 D 개 구한 후 이 들을 Rubin이 제시한 결합공식을 이용하여 결합(pooling)한 후 하나의 결과를 제시하게 된다.

다중 대체법은 여러 번의 대체표본으로 대체-내 분산 (within-imputation variance)과 대체-간 분산 (between-imputation variance)을 구하여 추정치의 총 분산을 추정하는 방법이다. 다중대체를 실시했을 때 생성되는 대체표본에서 추정량의 분산을 계산할 때 대체된 값들 간 차이에서 오는 분산이 추가되기 때문에 분산이 과소 추정되는 단일 대체법의 문제점을 해결할 수 있고 추정된 분산은 원 분산에 가까워진다.

1.1 고령화연구패널 7차 무응답 대체 방법

본 연구는 순차적 회귀 대체방법을 사용하여 고령화연구패널 7차 자료의 무응답 대체값을 산출하였다. Raghunathan, et. al. (2001)이 제안한 순차적 회

귀 대체(sequential regression imputation)는 대체할 변수가 여러 가지 분포를 따르는 경우와 제약(restriction)과 한계값(bound)이 있는 다양한 형태의 자료에서도 적용할 수 있는 방법이다. 대체할 변수가 정규 분포를 따르는 연속형 변수라면 일반회귀모형(regression model)을 적합시키며, 정규 분포를 따르지 않는 경우에는 정규성을 만족하도록 자료를 변환한 뒤 적합시킬 수 있다. 또한 대체할 변수가 이산형 변수이면 로짓회귀분석 모형(logistic regression model)을, 범주형 변수이면 분화(polytomous) 또는 일반화 로짓(generalized logit) 회귀모형을, 가산변수라면 포아송 회귀모형(poisson regression model)을 적합할 수 있다. 각 모형에서 사용한 공변량은 고령화연구패널 7차 자료 무응답 대체값 산출 결과보고서에 기술하였다.


고령화연구패널 7차 자료 무응답 대체값 산출은 미시간학의 조사연구센터(Survey Research Center)에서 개발된 IVEWare 프로그램을 사용하여 수행되었다. 연속형 변수와 계수형 변수의 다중 대체 횟수는 5회이지만 범주형 변수의 경우 다중 대체를 실시하게 되면 불확실성이 크기 때문에 상이한 결과가 나올 수 있다. 예를 들면, 학력의 경우 ‘초등학교 졸업’ 자가 ‘대학교 졸업’으로 나타날 수 있다. 이는 사용자에게 혼란을 줄 수 있으므로 범주형 변수의 경우 다중 대체보다는 단일 대체를 실시하였다.

1.2 다중 대체 자료의 결합

다중 대체된 자료 각각은 무응답이 대체되어 무응답이 없는 완전한 형태의 자료를 가지게 되므로 자료 각각에 대하여 연구목적에 알맞은 분석을 시행하면 된다. 예를 들어, 회귀분석을 시행하고자 한다면 m 개의 대체된 자료 각각에 대하여 관심있는 반응변수에 대한 회귀분석을 실시하면 된다. 이렇게 m 번의 분석을 실시하면 추정된 회귀계수(regression coefficients), 표준오차(standard errors), 그리고 검정통계량(test statistics)은 m 개 자료 각각으로부터 약간씩 다르게 나타나는데 이는 관심 변수가 완전하게 측정되지 못하고 무응답을 포함하므로 무응답값에 대한 불확실성에 근거한 차이를 나타내는 것이

다. 하지만 연구자의 분석 목적은 관심 자료에 대한 m 개의 서로 다른 결론이 아니라 한 개의 통합된 결론을 내리는 것이므로 m 개 분석의 결과를 통합하여 한 개의 결론을 도출하기 위하여 다음의 통합 과정을 거쳐야 한다.

〈그림 1〉 무응답을 포함한 결측 자료에 대하여 5개의 다중 대체를 실시한 경우의 예



다중 대체를 m 번 시행한 후 대체된 자료 각각에 대하여 알맞은 분석을 시행한 후 얻어진 모수의 추정값들을 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 이라 정의하고 이 모수들의 추정된 분산을 각각 $W_1, W_2, \dots, W_m$ 이라 정의하자. 예를 들어, 회귀분석을 실시한 경우 i 번째 대체자료에 근거한 회귀 분석에서 관심 설명 변수의 회귀계수의 추정값 벡터는 $\hat{\theta}_i$ 이 되고 그 회귀계수 벡터의 표준오차의 추정값의 제곱이 W_i 행렬로 표현된다. 이 경우 통합된 모수의 추정값은

$$\bar{\theta} = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i$$

으로 표현될 수 있다. 즉, 모수 추정값들의 평균값이 통합된 모수의 추정값이 된다.

통합된 모수의 분산의 추정값은 다음의 두 개의 분산 성분의 합으로 표현된다. 첫 번째 분산 성분은

$$\overline{W}_m = \frac{1}{m} \sum_{i=1}^m W_i$$

로서 대체된 자료들로부터 추정된 m 개의 모수의 분산들의 평균이다. 이 분산 성분은 대체내분산(within-imputation variance)이라 부른다. 두 번째 분산 성분은

$$B_m = \frac{1}{m-1} \sum_{i=1}^m (\hat{\theta}_i - \bar{\theta})^2$$

으로 표현되는데 이는 m 개의 대체된 자료로부터의 m 개의 모수의 추정값들 사이의 분산을 나타내므로 대체간분산(between-imputation variance)이라 부른다. 이 두 개의 분산 성분을 종합하여 계산한 모수의 분산에 대한 통합된 추정값은

$$T_m = \overline{W}_m + \frac{m+1}{m} B_m$$

으로 구할 수 있다.

관측값의 개수가 충분히 큰 경우, 일변량 모수(scalar parameter)에 대한 분포는 다음의 t -분포를 따른다.

$$(\theta - \bar{\theta}) T_m^{-\frac{1}{2}} \sim t_v$$

여기서, t -분포의 자유도 v 는

$$\nu = \left(\nu_0^{-1} + \widehat{\nu_{obs}^{-1}} \right)^{-1}$$

로 계산되는데 이 중 ν_0^{-1} 는

$$v_0 = (m-1) \left(1 + \frac{1}{m+1} \frac{\overline{W_m}}{B_m} \right)^2$$

으로 계산되고

$$\hat{\nu}_{obs} = (1 - \hat{\gamma}_m) \left(\frac{\nu_{com} + 1}{\nu_{com} + 3} \right) \nu_{com}$$

으로 나타나는데 이 때 ν_{com} 은 결측값이 없을 때 모수 θ 에 대한 추정의 자유도(degree of freedom)를 나타내고

$$\hat{\gamma}_m = \left(1 + \frac{1}{m} \right) \frac{B_m}{T_m}$$

으로서 무응답으로 인하여 손실된 모수 θ 에 대한 정보량(fraction of missing information about θ due to nonresponse)의 추정값이다. 모수의 분포가 t -분포를 따르므로 모수 θ 에 관한 t -검정을 시행하거나 모수의 신뢰구간(confidence interval)을 구할 수 있다. 이 통합 방법은 관심 모수들이 벡터로 표현될 때 다변량 검정 및 신뢰구간의 계산 등으로의 확장도 가능하다 (Rubin, 1987a).

2. 다중 대체 자료 분석 예제

고령화연구패널 7차년도 자료에 대하여 다중 대체를 5번 시행하여 하나의 데이터셋을 생성하였다. 고령화연구패널 7차년도 조사에 6,940명이 응답하였으므로 6,940건의 관측치가 있다. 따라서 다중 대체를 시행하여 생성된 데이터셋에는 6,940건의 다섯 배인 34,700(=6,940×5)건의 관측치가 있다. 또한 개인아이디, 가구아이디, 대체된 변수와 대체값에 대한 지시변수, 다중대체 번호를 나타내는 변수(imputation_)로 구성되었다. 지시변수는 ‘변수명_1’의 형태로 변수명을 지정하였다. 대체된 값인 경우 대체 지시변수의 값은 1, 대체된 값이 아닌 경우 대체 지시변수의 값은 0이다. 다중대체 번호를 나타내는 변수(imputation_)는 몇 번째로 대체된 자료인지를 나타내는 변수이다. 다중 대체

를 5번 시행하였으므로 다중대체 번호 변수(_imputation_)는 1, 2, 3, 4, 5의 값 중 하나의 값을 갖는다.

다중대체 번호 변수(_imputation_)로 구분되는 5개의 다중 대체된 자료에 대한 분석 결과를 통합하기 위하여 SAS PROC MIANALYZE 프로시저를 이용한다. PROC MIANALYZE 프로시저를 사용하여 분석된 자료의 모수들을 통합할 수 있다. PROC MIANALYZE에서 결과를 통합하기 위하여 자료의 형태는 다섯 개의 다중 대체된 자료가 하나의 데이터 셋으로 결합되어 있어야 한다. 따라서 병합한 데이터셋 Klosa_w07_imp는 적합한 형태이며, _imputation_ 변수를 이용하여 다섯 개의 대체된 자료를 분석한 후 결과를 통합하게 될 것이다.

다중대체 번호 변수 _imputation_ 로 정렬을 한 후 분석을 진행한다.

```
*다중대체 번호 변수 _imputation_ 로 정렬;  
PROC SORT DATA= Klosa_w07_imp ; BY _IMPUTATION_ ; RUN;
```

2.1 ‘거주 주택의 주택가격’의 단순 평균 계산

예를 들어 거주 주택의 주택가격(W07F007)의 평균을 산출하는 과정은 다음과 같다. 대체된 자료 각각에 대해 평균을 계산한 후 PROC MIANALYZE를 이용하여 각 대체된 자료별로 계산된 평균을 통합한다.

```

*각 대체된 자료별로 평균 계산;
PROC SURVEYMEANS DATA = Klosa_w07_imp
  VAR W07F007;
  BY _imputation_;
  ODS OUTPUT STATISTICS = mean;
RUN;

*자료별로 계산된 평균들의 통합;
PROC MIANALYZE DATA = mean;
  MODELEFFECTS mean;
  STDERR stderr;
RUN;

```

PROC SURVEYMEANS 프로시저를 이용하여 각 대체된 자료별로 평균을 계산한다. 이때 BY 명령문에 _imputation_ 변수를 입력하여 _imputation_ 별로 가구자산의 평균을 계산하여 mean이라는 SAS 데이터 셋을 생성하였다. 그 다음 PROC MIANALYZE 프로시저로 mean 데이터 셋에 저장된 평균값들을 통합한다. MODELEFFECTS 명령문에는 통합하고자 하는 통계량 변수를 써주고 STDERR 명령문에는 표준오차(stderr) 변수를 써준다. 이를 실행한 결과는 다음과 같다.

〈그림 2〉 대체된 자료 각각에 대한 거주 주택의 주택가격의 평균 및 단순 평균 계산 SAS Output

거주 주택의 주택가격 평균(imputation_=1)				
-----_imputation_=1-----				
The SURVEYMEANS Procedure				
Data Summary				
Number of Observations		6940		
Statistics				
Variable	N	Mean	Std Error of Mean	95% CL for Mean
w07F007	5854	23936	373.750207	23203.4383 24668.8152

거주 주택의 주택가격 평균(imputation_=2)					
----- _imputation_=2 -----					
The SURVEYMEANS Procedure					
Data Summary					
Number of Observations		6940			
Statistics					
Variable	N	Mean	Std Error of Mean	95% CL for Mean	
w07F007	5854	23940	373.798805	23206.7804	24672.3478

거주 주택의 주택가격 평균(imputation_=3)					
----- _imputation_=3 -----					
The SURVEYMEANS Procedure					
Data Summary					
Number of Observations		6940			
Statistics					
Variable	N	Mean	Std Error of Mean	95% CL for Mean	
w07F007	5854	23972	378.175084	23230.4240	24713.1497

거주 주택의 주택가격 평균(imputation_=4)					
----- _imputation_=4 -----					
The SURVEYMEANS Procedure					
Data Summary					
Number of Observations		6940			
Statistics					
Variable	N	Mean	Std Error of Mean	95% CL for Mean	
w07F007	5854	23897	373.813508	23163.7376	24629.3627

거주 주택의 주택가격 평균(imputation_=5)					
----- _imputation_=5 -----					
The SURVEYMEANS Procedure					
Data Summary					
Number of Observations		6940			
Statistics					
Variable	N	Mean	Std Error of Mean	95% CL for Mean	
w07F007	5854	23919	373.876830	23186.5533	24652.4267

거주 주택의 주택가격 단순 평균 산출 SAS Output							
The MIANALYZE Procedure							
Model Information							
Data Set		WORK.MEAN					
Number of Imputations		5					
Variance Information							
Parameter	Variance			DF	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency
	Between	Within	Total				
mean	766.988601	140390	141311	94291	0.006556	0.006534	0.998695
Parameter Estimates							
Parameter	Estimate	Std Error	95% Confidence Limits		DF	Minimum	Maximum
mean	23933	375.913158	23195.92	24669.49	94291	23897	23972
Parameter Estimates							
Parameter	t for H0: Parameter=Theta0			Pr > t			
mean	0			63.67 <.0001			

첫 번째 대체 데이터 셋의 거주 주택의 주택가격에 대한 평균은 23936이며, 두 번째 대체 데이터 셋의 주택가격에 대한 평균은 23940, 세 번째는 23972, 네 번째는 23897, 다섯 번째는 23919이다. 이를 통합한 결과 평균은 23933이며 표준오차는 375.913이다. 거주 주택의 주택가격의 평균에 대한 95% 신뢰구간은 (23195.92, 24669.49)로 산출되었다. 거주 주택의 주택가격의 평균이 0이라는 귀무가설에 대한 가설검정 결과는 t-통계량이 63.67, p-value가 <.0001로 유의수준 5%하에서 유의하게 나타난다.

2.2. 표본설계 가중치를 이용한 ‘거주 주택의 주택가격’ 평균 계산

제공된 표본설계 가중치를 이용하여 거주 주택의 주택가격의 평균 추정치를 계산해 보았다.

DATA total;

```

SET Klosa_w07_imp;
strata=compress(w07region1)||compress(w07region2)||compress(w07enu_type);
RUN;

*각 대체 자료 별 표본설계 가중치를 이용한 평균 계산;
PROC SURVEYMEANS DATA = total;
    STRATA strata;
    VAR w07F007;
    WEIGHT w07wgt_c;
    BY _imputation_;
    ODS OUTPUT STATISTICS = stat;
RUN;

*각 대체된 자료별로 계산된 표본설계 가중치를 이용한 평균을 통합하여 원 자료
의 총화평균 추정;
PROC MIANALYZE DATA =stat;
    MODELEFFECTS mean;
    STDERR stderr;
RUN;

```

표본설계에서 시도(w07region1), 동부/읍면동(w07region2), 주택유형(w07enu_type)을 층화변수로 사용하였으므로 SAS 분석을 위해 compress 함수를 사용하여 각 변수 값의 공백을 없애주고 ||을 사용하여 세 변수의 값들을 이어줌으로써 층화변수 strata를 생성하였다.

SAS Procedure SURVEYMEANS에서 BY변수를 사용하여 대체된 횟수에 따라 표본설계 가중치를 이용한 거주 주택의 주택가격의 평균 및 표준오차를 계산한 후 이들 통계량들을 자료명 stat에 저장하였다. 저장된 통계량들을 Procedure MIANALYZE를 사용하여 하나의 값으로 통합하였다. 이 때 MODELEFFECT 문에는 통합할 통계량 $\hat{\theta}_i$ (여기서는, 표본 설계 가중치를 이용한 평균)을 나타내는 변수 mean을 쓰고 STDERR문에는 W_i 의 제곱근인 평균의 표준 오차를 나타내는 stderr 변수를 써준다. 이를 실행한 결과는 다음과 같다.

〈그림 3〉 표본설계 가중치를 이용한 거주 주택의 주택가격의 평균 계산
SAS Output

The MIANALYZE Procedure							
Model Information							
Data Set		WORK.STAT					
Number of Imputations		5					
Variance Information							
Parameter	-----Variance-----			DF	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency
	Between	Within	Total				
mean	634.388663	216121	216882	324664	0.003522	0.003516	0.999297
Parameter Estimates							
Parameter	Estimate	Std Error	95% Confidence Limits		DF	Minimum	Maximum
mean	26243	465.705932	25330.46	27156.00	324664	26210	26277
Parameter Estimates							
Parameter	t for H0:			Pr > t			
	Theta0	Parameter=Theta0					
mean	0	56.35	<.0001				

표본 설계 가중치를 이용한 거주 주택의 주택가격의 평균은 26243이고 표준오차는 465.71로 나타난다. 표본 설계 가중치를 이용한 거주 주택의 주택가격의 평균에 대한 95% 신뢰구간은 (25330.46, 27156.00)으로 계산된다. 거주 주택의 주택가격이 0이라는 귀무가설은 t-통계량이 56.35, p-value가 <.0001로 5% 유의수준 하에서 유의하게 나타난다.

2.3 ‘거주 주택의 주택가격’에 대한 회귀분석

다중 대체된 자료는 회귀분석의 결과도 통합할 수 있다. 거주 주택의 주택가격 변수를 종속변수로 응답자의 연령(W07A002_AGE), 응답자의 성별(W07GENDER1), 거주형태(W07ENU_TYPE)를 독립변수로 하여 회귀분석을 수행할 수 있다. 이때 응답자의 성별과 거주형태는 이분형 변수이므로 응답자의 성별이 남자인 경우 1, 여자인 경우 0으로 더미변수를 생성하였으며, 거주형태는 아파트인 경우 1, 일반주택인 경우 0으로 더미변수를 생성하여 회귀모형에 포함하였다.

*응답자의 성별과 거주형태의 더미변수 생성;

```
DATA Klosa_w07_imp;  
    set Klosa_w07_imp;  
    W07GENDER1_M = (W07GENDER1 = 1);  
    W07ENU_TYPE_APT = (W07ENU_TYPE = 2);  
run;
```

*각 대체된 자료별로 회귀분석;

```
PROC REG DATA=Klosa_w07_imp OUTEST=outreg COVOUT;  
    MODEL w07F007 = W07A002_AGE W07GENDER1_M W07ENU_TYPE_APT ;  
    BY _imputation_;  
RUN;
```

*자료별로 추정된 회귀계수들의 통합;

```
PROC MIANALYZE DATA = outreg;  
    MODELEFFECTS Intercept W07A002_AGE W07GENDER1_M  
                    W07ENU_TYPE_APT ;  
RUN;
```

PROC REG 프로시저를 이용하여 각 대체 데이터 셋 자료별로 회귀분석을 수행하였으며, 그 결과를 outreg 데이터 셋으로 저장하였다. PROC MIANALYZE 프로시저를 이용하여 outreg 데이터셋에 저장된 각 자료별로 추정된 회귀계수들을 통합하였다. MODELEFFECTS 명령문에 intercept, W07A002_AGE, W07GENDER1, W07ENU_TYPE를 입력하여 각각의 회귀계수를 통합할 수 있다. 회귀계수를 통합한 결과는 다음과 같다.

〈그림 4〉 거주 주택의 주택가격 회귀분석 SAS Output

The MIANALYZE Procedure							
Model Information							
Data Set		WORK.OUTPUT					
Number of Imputations		5					
Variance Information							
Parameter	Between	Variance Within	Total	DF	Relative Increase in Variance	Fraction Missing Information	Relative Efficiency
Intercept	33650	7693698	7734079	146740	0.005248	0.005235	0.998954
w07A002_AGE	7.702711	1458.356544	1467.599797	100838	0.006338	0.006318	0.998738
w07GENDER1_M	3193.246622	567317	571149	88865	0.006754	0.006731	0.998656
w07ENU_TYPE_APT	2156.406511	578769	581357	201893	0.004471	0.004461	0.999109
Parameter Estimates							
Parameter	Estimate	Std Error	95% Confidence Limits	DF	Minimum	Maximum	
Intercept	29269	2781.020961	-189.81 34720.10	146740	29081	29530	
w07A002_AGE	-114.709913	38.309265	-189.80 -39.62	100838	-118.608607	-111.773607	
w07GENDER1_M	858.419366	755.743998	-622.83 2339.67	88865	784.598358	934.515880	
w07ENU_TYPE_APT	5298.325772	762.467667	3803.91 6792.74	201893	5244.671519	5353.954414	
Parameter Estimates							
Parameter	t for H0:						
	Theta0	Parameter=Theta0	Pr > t				
Intercept	0	10.52	<.0001				
w07A002_AGE	0	-2.99	0.0028				
w07GENDER1_M	0	1.14	0.2560				
w07ENU_TYPE_APT	0	6.95	<.0001				

회귀 모형의 절편(intercept)은 29269, 응답자의 연령(W07A002_AGE), 응답자의 성별(W07GENDER1_M), 거주형태(W07ENU_TYPE)의 회귀계수는 각각 -114.71, 858.42, 2598.33으로 나타났다. 절편을 포함한 네 회귀모수의 표준오차는 각각 2781.02, 38.31, 755.74, 762.47로 추정되었다. 절편 및 각 변수의 회귀계수가 0인가를 검정하는 t 통계량은 각각 10.52, -2.99, 1.14, 6.95 으로서, 5% 유의수준 하에서 응답자의 연령, 거주형태의 회귀 계수는 통계적으로 유의하였다.

참고문헌

- Little R. J. A. (1988), "Missing data adjustments in large surveys," *Journal of Business and Economic Statistics* , 6, 287-301.
- Rubin D.B. (1987) *Multiple Imputation for Nonresponse in Surveys* , John Wiley: New York.
- Schafer, J.L. (1997) *Analysis of Incomplete Multivariate Data*, Chapman and Hall, London, UK.
- Song, J., Lee S. Y., Yoon, C., Yoon, R., Song, K-H., Kim, B., Chang, J., and Lee, H. (2007) *KLoSA Report* , Korea Labor Institute.
- SAS/STAT 14.1 User's Guide The MI Procedure(2015).
- SAS/STAT 9.2 User's Guide The MIANLYZE Procedure(2008).